

Penugasan Kelompok
Mata Kuliah Natural Language Processing
Topik: Eksplorasi Isu dalam Text Clustering

Penugasan ini dilaksanakan secara **berkelompok**. Setiap kelompok diminta melakukan eksplorasi terhadap proses text clustering pada sebuah dataset teks yang diperoleh secara mandiri, kemudian menganalisis beberapa isu penting dalam clustering, yaitu:

1. evaluasi cluster
2. penentuan jumlah cluster
3. pemberian label cluster

Penugasan ini bersifat eksploratif dan analitis. Oleh karena itu, setiap kelompok tidak hanya diminta menjalankan algoritma clustering, tetapi juga menjelaskan proses, alasan pemilihan metode, hasil yang diperoleh, serta interpretasi terhadap hasil tersebut.

Ketentuan Dataset

1. Setiap kelompok wajib **mencari dataset secara mandiri**.
2. Dataset yang digunakan **harus berupa data teks**. Contoh judul berita, artikel pendek, abstrak, review produk, komentar pengguna, tweet, atau dokumen teks lain yang sejenis.
3. Dataset harus memiliki jumlah data minimal **50 dokumen teks**.
4. Setiap kelompok wajib mencantumkan:
 - o sumber dataset,
 - o deskripsi singkat isi dataset,
 - o jumlah dokumen,
 - o karakteristik umum data.

Instruksi

Setiap kelompok diminta untuk melaksanakan tahapan berikut:

1. Preprocessing Teks
Melakukan preprocessing yang relevan terhadap dataset, misalnya: case folding, tokenization, stopword removal, stemming atau lemmatization, pembersihan tanda baca, angka, atau karakter lain jika diperlukan. Setiap kelompok wajib menjelaskan:
 - a. tahapan preprocessing yang digunakan,
 - b. alasan penggunaan tahapan tersebut.
2. Representasi Dokumen
Mengubah dokumen teks menjadi representasi numerik yang dapat diproses oleh algoritma clustering, misalnya: Bag-of-Words atau TF-IDF. Setiap kelompok wajib menjelaskan metode representasi yang digunakan serta alasan pemilihannya.
3. Penerapan Clustering
Menerapkan minimal satu algoritma clustering pada dataset teks.
 - a. Setiap kelompok wajib mencoba beberapa variasi jumlah cluster.
 - b. Hasil clustering dari beberapa variasi tersebut harus dibandingkan.
4. Eksplorasi Isu
Setiap kelompok wajib membahas secara khusus tiga aspek berikut:
 - a. Evaluasi Cluster

Kelompok harus menjelaskan bagaimana kualitas cluster dinilai. Evaluasi harus mencakup:

- i. evaluasi kuantitatif, misalnya dengan metrik seperti silhouette score, Davies-Bouldin index, atau metrik lain yang relevan,
 - ii. evaluasi kualitatif, misalnya dengan membaca isi dokumen pada cluster tertentu, melihat kesamaan tema, atau memeriksa kata-kata dominan.
- b. Penentuan Jumlah Cluster
- Kelompok harus mencoba beberapa jumlah cluster, kemudian:
- i. membandingkan hasilnya,
 - ii. menjelaskan konsekuensi jika jumlah cluster terlalu sedikit atau terlalu banyak,
 - iii. menentukan jumlah cluster yang dianggap paling sesuai disertai alasan yang jelas.
- c. Cluster Labeling
- Kelompok harus memberikan label atau nama pada cluster yang dihasilkan. Label dapat ditentukan berdasarkan:
- i. kata-kata dominan,
 - ii. kata dengan bobot tertinggi,
 - iii. tema umum isi dokumen,
 - iv. atau gabungan dari beberapa pendekatan tersebut.
- Kelompok juga harus menjelaskan:
- i. dasar penentuan label,
 - ii. kesesuaian label dengan isi cluster,
 - iii. kendala yang muncul jika ada cluster yang sulit diberi label.

5. Luaran yang Harus Dikumpulkan

- a. Laporan
- b. File Program
- c. Presentasi

6. Pertanyaan Panduan

Dalam laporan, setiap kelompok wajib menjawab pertanyaan berikut:

- a. Bagaimana kualitas suatu cluster dinilai dalam eksperimen yang dilakukan?
- b. Metrik evaluasi apa yang digunakan, dan mengapa metrik tersebut dipilih?
- c. Apakah hasil evaluasi kuantitatif sejalan dengan interpretasi isi cluster?
- d. Bagaimana kelompok menentukan jumlah cluster yang paling sesuai?
- e. Apakah jumlah cluster terbaik menurut metrik sama dengan jumlah cluster terbaik menurut interpretasi kelompok?
- f. Bagaimana proses pemberian label pada cluster dilakukan?
- g. Cluster mana yang paling mudah diberi label, dan cluster mana yang paling sulit?
- h. Apa tantangan utama yang ditemui selama melakukan text clustering?

Batas waktu: 21 April 2026 pukul 23.59 WIB